

# 从 BoxFusion 到可见性感知的概率化 3D 框融合

## 结论

你的判断是准确的：目前的改动更像“把 BoxFusion 做得更强”，而不是已经提出了一个新的方法原理。

- `real-score`：属于评测或输出修复；
- 直接接入 Boxer：属于更强的几何先验；
- 固定 Top-K：属于启发式筛选；
- FastSAM/F4 补 proposal：属于召回增强。

它们的组合可以带来好结果，但审稿人很可能会追问：**你提出了什么别人不能直接替换、不能简单拼装得到的机制？**

这些实验没有白做。它们已经把真正值得研究的问题暴露出来：

BoxFusion 将不同视角的 3D 框基本当作同等可靠的观测，再用投影 IoU 进行随机优化；但在真实 RGB-D 流中，不同视角对中心、尺寸、朝向的约束能力完全不同，且遮挡与自由空间信息没有被显式建模。

BoxFusion 使用多视图关联和随机优化实现框融合，但并未围绕“部分可见观测的参数级可信度”建立统一的观测模型。[BoxFusion 论文](#)

建议不要继续把 F4、Boxer、Top-K 作为三个平行创新，而是转向一个更像论文核心的方法：

## 可见性感知的参数级不确定性 3D 框融合

暂定名称：

**VAPF-3D: Visibility-Aware Probabilistic Box Fusion for Online Open-Vocabulary 3D Detection**

核心问题不是“选哪几个视角”，而是：

每个视角究竟能可靠地约束 3D 框的哪一个参数？它提供的是正证据、遮挡证据，还是自由空间反证据？

# 总体框架

单帧原生 3D 框 + 2D 掩码 + 深度图 + 位姿



可见性与局部几何观测分解



参数级不确定性估计（中心/尺寸/朝向）



分布式跨帧关联与异常观测抑制



可见性约束的概率化多视图框融合



全局开放词汇 3D 对象框

## 1. 可见性与局部几何观测分解

对每个对象在每一帧中，不只保存一个 3D 框和一个 score，而是从掩码、深度、相机视角中提取：

- 可见比例：物体有多少真正被看到；
- 截断比例：是否被图像边界截断；
- 遮挡比例：是否被前景深度挡住；
- 深度有效率与深度方差；
- 观察角度：正面、侧面、斜视；
- 3D 框投影与 2D 掩码的一致性；
- 3D 框体积是否侵入已观测自由空间。

特别是最后一项：

- 相机到深度表面之前的区域是**自由空间**；
- 深度表面之后是未知或被遮挡空间；
- 如果候选 3D 框大面积落入多个视角的自由空间，它很可能是错误框；
- 如果它在某帧不可见是因为被前景挡住，则不应错误惩罚它。

这会让方法从“只看 2D 框投影是否对齐”，提升到“显式理解该视角能否看见、应当看见什么”。

## 2. 参数级不确定性，而不是一个总 score

为第  $i$  个观测框估计：

$$U_i = (u_i^{center}, u_i^{size}, u_i^{yaw}, u_i^{semantic})$$

分别表示：

- $u\_center$ ：中心位置是否可信；
- $u\_size$ ：尺寸是否可信；
- $u\_yaw$ ：朝向是否可信；
- $u\_semantic$ ：开放词汇语义是否可信。

例如：

- 正面可见但侧面不可见：中心相对可靠、深度尺寸不可靠；
- 轮廓完整但深度噪声大：二维边界可靠、中心深度不可靠；
- 近似正方形物体：朝向天然不确定；
- 遮挡严重：尺寸和语义均不应高置信更新。

候选整体质量可定义为：

$$q_i = q_i^{det} q_i^{depth} q_i^{mask} q_i^{semantic} q_i^{multi-view}$$

关键不再是硬删除低质量视角，而是：**让每个视角只更新它真正可靠的参数。**

### 3. 不确定性感知关联

将 BoxFusion 原来的硬 3D NMS/匹配升级为分布式关联：

$$D_{ij} = (B_i - B_j)^T (\Sigma_i + \Sigma_j)^{-1} (B_i - B_j)$$

其中  $\Sigma_i$  由参数不确定性构成。

直观上：

- 两个框中心差得较多，但都处于高深度不确定区域时，不能轻易判为不同实例；
- 两个框位置接近、类别相同，但位置和外观都确定时，应严格避免错误合并；
- 同类桌椅相邻时，可加入对象级 CLIP 特征和掩码投影一致性，减少合并错误。

这能形成比“3D NMS + 规则匹配”更清楚的关联贡献。

### 4. 可见性约束的鲁棒概率融合

不再做所有视角等权的投影 IoU 优化，而是优化：

$$\min_B \sum_i w_i \rho \left( L_{\text{proj}}^i(B) + \lambda L_{\text{surface}}^i(B) + \mu L_{\text{free-space}}^i(B) \right)$$

其中：

- $L_{proj}$ : 3D 框投影与 2D 掩码或框的一致性；
- $L_{surface}$ : 3D 框表面与深度观测的一致性；
- $L_{free-space}$ : 3D 框侵入自由空间的惩罚；
- $w_i$ : 由参数级不确定性和可见性决定；
- $\rho$ : 鲁棒损失，避免单个异常视角拉偏全局框。

预期作用：

- AP15：错误框被自由空间反证抑制；
- AP25：关联更稳定；
- AP50：中心、尺寸和朝向由可靠视角分别精炼。

## 现有工作在新框架中的位置

| 现有工作                 | 在新框架中的位置       | 是否作为主创新  |
|----------------------|----------------|----------|
| native real-score    | 基准评测和初始质量输入    | 否        |
| Boxer active lifting | 产生 3D 框残差或先验均值 | 否，作为几何先验 |
| Reliable-view Top-K  | 替换成连续不确定性权重    | 不保留固定 K  |
| F4/Stream3Dv2-lite   | 未解释区域候选补全模块    | 可作为第二贡献  |

主贡献应是“如何融合不完整、多噪声、多质量的观测”，而不是“使用了哪些额外模型”。

F4 可以作为第二位贡献：

对于全局对象投影无法解释的区域，生成候选；只有在跨帧可见性、深度一致性和语义一致性均满足时，候选才进入概率融合。

这样 F4 不再只是“加了一个 FastSAM”，而是整个观测模型的自然输入。

## 与已有工作的差异

“不确定性融合”和“可见性感知”已有相关工作，因此不能把这两个词本身当成创新。[UA-Fusion](#) 与 [多视图对象重建中的不确定性建模](#) 均涉及相关思想。

本方法的差异应明确写成：

1. 面向**在线、重建自由、开放词汇 3D 框融合**，不是点云检测或网格重建；
2. 使用**对象框参数级**不确定性，不是像素级深度不确定性；

3. 使用深度射线构造**自由空间、表面、遮挡**三类观测证据；
4. 不确定性同时作用于**关联、框精炼、融合和最终排序**；
5. 保持 BoxFusion 的流式和轻量特点。

OpenM3D 已在离线多视图场景中通过跨视图分组产生高质量伪框。因此“多视图候选补全”本身不宜作为唯一创新；差异应落在**在线增量、对象状态维护和可见性约束融合**上。[OpenM3D](#)

## 下一步行动

1. **做误差诊断**：记录每个观测的遮挡率、深度方差、视角、重投影误差，并分析它们与真实 3D IoU 的相关性。
2. **先实现无训练版本**：由深度方差、掩码完整度、可见比例、跨帧框方差构造参数级权重，验证参数级加权是否优于固定 Top-K。
3. **加入自由空间约束**：验证其能否减少错误大框、遮挡误融合和 AP50 失败案例。
4. **最后再接入 F4**：将其作为候选补全模块，而不是主方法本身。

## 一句话定位

你现在不是“没有创新”，而是还停在**增强 BoxFusion**阶段；下一步应把工作重构成一个明确的新问题：

如何在**不重建场景**的前提下，对部分可见、质量不均的多视图 3D 框进行可见性感知的概率融合。