

# BoxFusion 相关方法比较与改进思路

## 1. 相关方法定位：在线、开放词汇与无稠密重建

严格同时满足“在线 + 开放词汇 + 不做稠密场景重建 + 输出 3D 框”的工作非常少。BoxFusion 仍是最贴合该设定的基线；其余方法更适合作为思想来源或补充对比，而不能全部作为公平的主对比方法。

| 方法           | 在线          | 开放词汇 / 开放集             | 不依赖稠密场景重建             | 与本课题的关系                            |
|--------------|-------------|------------------------|-----------------------|------------------------------------|
| BoxFusion    | 是           | 是                      | 是                     | 最直接基线：框级状态维护与多视图融合                 |
| DetAny4D     | 是，流式 RGB 视频 | 开放集                    | 基本是                   | 最值得借鉴时序一致性与因果时空建模；但不是 RGB-D 多视图框融合 |
| Boxer        | 可在线跟踪       | 通过 OWLv2 等开放词汇 2D 检测实现 | 是，但可用稀疏点云或深度          | 最直接的单视图 3D 框提升器；不确定性回归值得借鉴         |
| OpenSU3D     | 增量式         | 是                      | 不做传统稠密网格，但维护实例级 3D 表示 | 借鉴实例语义记忆与跨视图特征融合，不宜作直接框检测对比        |
| EmbodiedSAM  | 是           | 零样本 / 开放词汇潜力           | 否，依赖 3D 点云实例分割        | 借鉴在线关联和查询状态维护                      |
| OnlineAnySeg | 是           | 是                      | 否，采用体素哈希与逐步重建         | 借鉴高效关联，但不能称为无重建方法                  |

## 三条重点借鉴路线

### 1. DetAny4D：将跨帧稳定性作为显式目标

DetAny4D 针对逐帧检测导致的抖动与不一致，采用几何感知的因果时空建模。可将其思想改造为：

- 不让每个新视图都立即参与融合；
- 先判断该视图对中心、尺寸、朝向中哪些参数具有有效观测；
- 对遮挡或截断视图，仅更新可信参数，其余参数保留历史后验。

相较于“按质量为框加权”，这种做法把标量权重提升为**参数级、可见性感知的状态更新**。

### 2. Boxer：将不确定性并入融合，而不只改善候选框

Boxer 通过开放词汇 2D 检测、Transformer 式 3D lifting 和多视图融合得到全局 3D OBB，并在回归中引入 aleatoric uncertainty。参见其[项目页](#)。

可形成的核心差异是：Boxer 判断“这个框整体是否准确”；本研究判断“该视图对 3D 框的不同参数分别是否可靠”，并依据可见表面与自由空间证据决定是否更新。

可设置以下对比：

- Boxer 式整体置信度融合；
- 参数级协方差融合；
- 参数级协方差融合 + 自由空间反证约束。

### 3. OpenSU3D / EmbodiedSAM：借鉴实例记忆，但不引入点云地图

这类方法维护实例级对象状态、语义特征和跨视图关联，而不只依赖当前帧。可将 BoxFusion 的全局框扩展为轻量对象记忆：

$$\mathcal{O}_j = \{B_j, \Sigma_j, F_j, H_j, V_j\}.$$

其中：

- $B_j$ ：全局 3D 框；
- $\Sigma_j$ ：参数不确定性；
- $F_j$ ：开放词汇语义记忆；
- $H_j$ ：可见性历史；
- $V_j$ ：已被解释的视图区域。

该表示仍是对象框图，而不是稠密场景重建。

### 推荐的创新主线

面向流式 RGB-D 的可见性—不确定性耦合对象状态滤波：仅维护对象级 3D 框状态；从当前视图的可见表面、遮挡关系、深度残差和重投影一致性中，推断该观测对中心、尺寸和朝向的参数级可信度，并以概率后验方式更新全局框。

对应三个核心模块：

- **可见性解析**：区分可见表面、遮挡未知区与自由空间冲突区；
- **参数级不确定性预测**：输出中心、尺寸、朝向的协方差，而非一个总分；
- **反事实多视图融合**：若候选框投影落在当前深度的自由空间，则作为负证据抑制更新；若区域被遮挡，则不将“未见到”误判为反证。

实验上，BoxFusion、Boxer 和 DetAny4D 可作为最有价值的近邻参考；OpenSU3D、EmbodiedSAM 和 OnlineAnySeg 更适合放入相关工作与模块消融，而不是硬做同表公平比较。

## 2. 六个方法对 BoxFusion 改进的可迁移性

六个方法正好覆盖 BoxFusion 的三处短板：**候选框质量、跨视图关联、融合状态更新**。但不应直接堆叠模块，而应将其统一为“可见性感知的对象级概率状态估计”。

| 方法        | 核心长处                       | 对 BoxFusion 的可迁移点 | 是否建议直接加入 |
|-----------|----------------------------|-------------------|----------|
| BoxFusion | 流式 RGB-D、开放词汇、框级在线融合、无稠密重建 | 基础框架              | 基线       |

| 方法           | 核心长处                                             | 对 BoxFusion 的可迁移点                | 是否建议直接加入                        |
|--------------|--------------------------------------------------|----------------------------------|---------------------------------|
| DetAny4D     | 因果时空建模，降低连续预测抖动                                  | 当前帧不应独立决定 3D 框；<br>引入短时历史状态与延迟更新 | 借鉴思想，<br>不直接复现网络                |
| Boxer        | 开放词汇 2D 框提升至 3D OBB；<br>预测 aleatoric uncertainty | 候选框的几何不确定性与深度质量编码                | 最值得借鉴，<br>但不能仅将 Boxer<br>作为外接模块 |
| OpenSU3D     | 实例级语义记忆与多视图特征融合                                  | 对象级 CLIP 特征库、历史视图选择              | 可轻量迁移                           |
| EmbodiedSAM  | 在线实例关联、跨帧查询状态                                    | 用对象状态而不只是 3D NMS<br>完成关联         | 借鉴关联机制，<br>不引入点云分割主干            |
| OnlineAnySeg | 高效在线多视图掩码合并                                      | 用 2D mask 重叠与一致性辅助关联、<br>可见性判断   | 仅使用 2D mask<br>证据，<br>不复制体素哈希地图 |

需要特别区分：OpenSU3D、EmbodiedSAM 和 OnlineAnySeg 都维护点、体素或实例级 3D 场景表示，因此不应被描述为“无重建的直接对比方法”。本研究应保持 BoxFusion 的对象框图，仅维护对象状态，不维护稠密场景。

## 2.1 统一对象状态

$$\mathcal{O}_j = \{B_j, \Sigma_j, F_j, H_j\}.$$

其中：

- $B_j$ ：全局 3D 框；
- $\Sigma_j$ ：中心、尺寸、朝向的参数级不确定性；
- $F_j$ ：开放词汇语义记忆；
- $H_j$ ：各视图的可见性与观测历史。

核心问题不是“为每个候选框计算一个质量分数”，而是：

当前视图实际观测到了物体的什么部分，因此能可靠更新全局 3D 框的哪些参数？

## 2.2 四个改进模块

### 模块一：可见性—观测解析

输入候选框、2D mask、深度、相机位姿和当前全局框投影，将观测区域划分为：

- 可见表面证据；
- 被遮挡的未知区域；
- 自由空间冲突区域。

自由空间中不应出现物体。若候选框大量投影到自由空间，应将其作为负证据；若该区域只是被遮挡，则不能因为“未见到”而否定该框。这是区别于普通质量加权的关键。

### 模块二：参数级不确定性预测（借鉴 Boxer）

不输出单一总置信度，而输出：

$$\Sigma_i = \text{diag}(\sigma_{x,y,z}^2, \sigma_{l,w,h}^2, \sigma_\theta^2).$$

例如，正视图可能较好约束宽、高，却难以确定深度；边缘截断视图只允许更新可见侧的中心位置，不应强行修正尺寸和朝向。Boxer 的不确定性回归可作为实现起点，但本研究的重点是将不确定性与可见性、自由空间联合约束。

### 模块三：可信关联（借鉴 EmbodiedSAM 与 OnlineAnySeg）

将 BoxFusion 当前的“3D 距离 / IoU + NMS”升级为不确定性感知关联：

$$A_{ij} = \lambda_g A_{ij}^{geo}(\Sigma) + \lambda_s A_{ij}^{sem}(F) + \lambda_m A_{ij}^{mask} - \lambda_f A_{ij}^{free}.$$

其中，几何项采用马氏距离而不是固定阈值；语义项来自历史多视图特征；mask 项检验重投影一致性；自由空间项抑制错误匹配。这有助于避免部分可见物体被错误并入邻近实例。

### 模块四：概率后验融合（借鉴 DetAny4D 的时序一致性）

BoxFusion 当前融合倾向于寻找一个多视图 IoU 最优的框。可改为对象状态的在线后验更新：

$$p(B_j \mid z_{1:t}) \propto p(z_t \mid B_j, V_t, \Sigma_t) p(B_j \mid z_{1:t-1}).$$

对低可见、强遮挡或存在自由空间冲突的观测，降低甚至拒绝更新；仅让信息增益高的观测更新相应参数。DetAny4D 的关键启发不是直接替换为时空 Transformer，而是将稳定性设为明确的建模目标。

## 2.3 推荐论文主线

提出一种无需稠密场景重建的可见性—不确定性耦合在线 3D 框融合方法。该方法将每个视图建模为对全局 3D 框不同参数的部分观测，以可见表面、遮挡未知区和自由空间反证共同估计参数级不确定性，并进行鲁棒后验更新。

## 2.4 建议的消融顺序

1. BoxFusion 原始融合；
2. • Boxer 式整体不确定性；
3. • 参数级不确定性；
4. • 可见性门控；
5. • 自由空间反证；
6. • 多视图语义记忆。

若整体不确定性带来的提升有限，而“参数级不确定性 + 自由空间反证”能同时改善 AP50、中心误差、尺寸误差、朝向误差和时序稳定性，则创新论证会更扎实。